

# Práctica 1.1 — Probabilidad y Estadística

## Análisis de la evolución poblacional mundial

En esta práctica se trabaja con datos reales de población obtenidos de **Our World in Data (OWID)**, cuya fuente original es **United Nations, World Population Prospects (2024)**.

El propósito es familiarizarse con un conjunto de datos real y comprobar que el entorno de trabajo (Python, Pandas, NumPy, Jupyter) funciona correctamente.

## Objetivo

Utilizar un conjunto de datos real para comprobar el funcionamiento del entorno de análisis de datos y aplicar medidas estadísticas descriptivas básicas utilizando Pandas y NumPy.

## Actividad 1 — Identificación de la fuente

**Propósito:** reconocer la procedencia del conjunto de datos antes de utilizarlo y documentar correctamente su fuente.

### Cita de la fuente:

UN, World Population Prospects (2024) – processed by Our World in Data.  
"Annual change in population – UN WPP" [dataset]. United Nations, "World Population Prospects"; United Nations, "World Population Prospects - Interim Update" [original data].

### Preguntas

1. **¿Quién produjo originalmente los datos?** Naciones Unidas (United Nations), a través de World Population Prospects (2024).
2. **¿Qué organización los procesa para su utilización en Our World in Data?** Our World in Data (OWID) procesa y estandariza los datos originales de la ONU.
3. **¿Qué representa la variable que analizarás?** "Annual change in population" es el cambio *neto* anual de población: la diferencia entre la población al 1 de julio de dos años consecutivos, considerando nacimientos, muertes y migración en conjunto.

## Actividad 2 — Carga y exploración de datos

**Propósito:** comprobar que el entorno de Python, Pandas y Jupyter funciona correctamente y realizar una primera exploración del dataset.

## 2.1 Importar las bibliotecas

```
In [1]: import pandas as pd
import numpy as np
```

## 2.2 Cargar el archivo CSV

```
In [2]: dataframe = pd.read_csv("../data/raw/annual-population-growth/annual-population-gro
```

## 2.3 Explorar el DataFrame

```
In [3]: dataframe.head(5)
```

```
Out[3]:
```

|   | Entity      | Code | Year | Annual change in population | Annual population change (Projected) |
|---|-------------|------|------|-----------------------------|--------------------------------------|
| 0 | Afghanistan | AFG  | 1951 | 103163.0                    | NaN                                  |
| 1 | Afghanistan | AFG  | 1952 | 108441.0                    | NaN                                  |
| 2 | Afghanistan | AFG  | 1953 | 108919.0                    | NaN                                  |
| 3 | Afghanistan | AFG  | 1954 | 111251.0                    | NaN                                  |
| 4 | Afghanistan | AFG  | 1955 | 119027.0                    | NaN                                  |

```
In [4]: dataframe.shape
```

```
Out[4]: (38400, 5)
```

```
In [5]: dataframe.columns.tolist()
```

```
Out[5]: ['Entity',
'Code',
'Year',
'Annual change in population',
'Annual population change (Projected)']
```

```
In [6]: dataframe.dtypes
```

```
Out[6]: Entity          str
Code          str
Year          int64
Annual change in population  float64
Annual population change (Projected)  float64
dtype: object
```

```
In [7]: df = dataframe
```

```
In [8]: df.describe()
```

```
Out[8]:
```

|       | Year         | Annual change in population | Annual population change (Projected) |
|-------|--------------|-----------------------------|--------------------------------------|
| count | 38400.000000 | 1.868800e+04                | 1.971200e+04                         |
| mean  | 2025.500000  | 2.063019e+06                | 8.375481e+05                         |
| std   | 43.300872    | 9.440859e+06                | 5.816745e+06                         |
| min   | 1951.000000  | -3.315935e+06               | -2.291035e+07                        |
| 25%   | 1988.000000  | 1.781000e+03                | -9.742750e+03                        |
| 50%   | 2025.500000  | 4.689800e+04                | 9.350000e+01                         |
| 75%   | 2063.000000  | 3.021128e+05                | 1.411160e+05                         |
| max   | 2100.000000  | 9.337137e+07                | 7.206736e+07                         |

```
In [9]: df.isnull().sum()
```

```
Out[9]: Entity          0
Code          1200
Year          0
Annual change in population    19712
Annual population change (Projected)  18688
dtype: int64
```

```
In [10]: df["Entity"].nunique()
```

```
Out[10]: 256
```

### Preguntas

1. **¿Cuántas filas y columnas tiene el dataset?** 38,400 filas y 5 columnas.
2. **¿Qué tipo de datos contiene la variable Year ?** int64 (números enteros).
3. **¿Existen valores faltantes?** Sí: Code tiene 1,200 valores nulos, Annual change in population tiene 19,712 y Annual population change (Projected) tiene 18,688.
4. **¿Cuántas entidades diferentes contiene el dataset?** 256 (incluye países y también entidades agregadas como continentes o "World").

## Actividad 3 — Estadística descriptiva

**Propósito:** aplicar medidas estadísticas básicas a una variable poblacional.

Se selecciona el año **2020** (periodo histórico) y se filtran los datos correspondientes. Sobre la variable **"Annual change in population"** se calculan: media, mediana, varianza, desviación estándar, mínimo y máximo.

```
In [11]: anio = 2020
df_anio = df[df["Year"] == anio]
df_anio.head(3)
```

```
Out[11]:
```

|     | Entity      | Code   | Year | Annual change in population | Annual population change (Projected) |
|-----|-------------|--------|------|-----------------------------|--------------------------------------|
| 69  | Afghanistan | AFG    | 2020 | 1212852.0                   | NaN                                  |
| 219 | Africa (UN) | UN_AFR | 2020 | 32815675.0                  | NaN                                  |
| 369 | Albania     | ALB    | 2020 | -13061.0                    | NaN                                  |

```
In [12]: variable = "Annual change in population"

media = df_anio[variable].mean()
mediana = df_anio[variable].median()
varianza = df_anio[variable].var()
desviacion_estandar = df_anio[variable].std()
minimo = df_anio[variable].min()
maximo = df_anio[variable].max()

print("Media:", media)
print("Mediana:", mediana)
print("Varianza:", varianza)
print("Desviación estándar:", desviacion_estandar)
print("Mínimo:", minimo)
print("Máximo:", maximo)
```

Media: 2124908.84765625  
Mediana: 34293.5  
Varianza: 90687335031103.64  
Desviación estándar: 9522989.815761836  
Mínimo: -494016.0  
Máximo: 75707590.0

```
In [13]: entidad_min = df_anio.loc[df_anio[variable].idxmin(), "Entity"]
entidad_max = df_anio.loc[df_anio[variable].idxmax(), "Entity"]

print("Entidad con el valor mínimo:", entidad_min)
print("Entidad con el valor máximo:", entidad_max)
```

Entidad con el valor mínimo: Venezuela  
Entidad con el valor máximo: World

## Preguntas

1. ¿Cuál es el valor de la media?  $\approx 2,124,908.85$  personas.
2. ¿Cuál es el valor de la mediana? 34,293.5 personas.
3. ¿Cuál es el valor de la desviación estándar?  $\approx 9,522,989.82$  personas.
4. ¿Qué entidad presenta el valor mínimo y cuál el máximo? El valor mínimo lo presenta **Venezuela** (-494,016) y el máximo lo presenta **"World"** (75,707,590). Nota: "World" es una entidad agregada (no un país individual), por lo que representa la suma global, no el país con mayor crecimiento.

## Actividad 4 — Comprobación del entorno

**Propósito:** comprobar que el notebook está utilizando correctamente las herramientas configuradas para la práctica.

In [14]: `import sys`

```
print("Python:", sys.version)
print("Pandas:", pd.__version__)
print("NumPy:", np.__version__)
```

Python: 3.12.10 (tags/v3.12.10:0cc8128, Apr 8 2025, 12:21:36) [MSC v.1943 64 bit (AMD64)]

Pandas: 3.0.5

NumPy: 2.5.2

Se verifica que las versiones mostradas corresponden al entorno virtual ( `.venv` ) configurado para la práctica. Finalmente, se debe ejecutar **Restart Kernel and Run All Cells** para comprobar que todo el notebook se reproduce correctamente de principio a fin.

## Análisis adicional — País con "A" (2006–2026)

Se filtran los datos de **Argentina** entre los años 2006 y 2026, y se calculan media, mediana, varianza y desviación estándar de "Annual change in population".

In [15]: `pais = "Argentina"`  
`df_pais_fechas = df[(df["Entity"] == pais) & (df["Year"] >= 2006) & (df["Year"] <=`  
`df_pais_fechas[["Entity", "Year", "Annual change in population"]]`

Out[15]:

|      | Entity    | Year | Annual change in population |
|------|-----------|------|-----------------------------|
| 1555 | Argentina | 2006 | 405327.0                    |
| 1556 | Argentina | 2007 | 394654.0                    |
| 1557 | Argentina | 2008 | 407384.0                    |
| 1558 | Argentina | 2009 | 430681.0                    |
| 1559 | Argentina | 2010 | 433862.0                    |
| 1560 | Argentina | 2011 | 441961.0                    |
| 1561 | Argentina | 2012 | 431063.0                    |
| 1562 | Argentina | 2013 | 420735.0                    |
| 1563 | Argentina | 2014 | 441618.0                    |
| 1564 | Argentina | 2015 | 452940.0                    |
| 1565 | Argentina | 2016 | 423301.0                    |
| 1566 | Argentina | 2017 | 388586.0                    |
| 1567 | Argentina | 2018 | 365978.0                    |
| 1568 | Argentina | 2019 | 318593.0                    |
| 1569 | Argentina | 2020 | 218491.0                    |
| 1570 | Argentina | 2021 | 120322.0                    |
| 1571 | Argentina | 2022 | 95622.0                     |
| 1572 | Argentina | 2023 | 130498.0                    |
| 1573 | Argentina | 2024 | NaN                         |
| 1574 | Argentina | 2025 | NaN                         |
| 1575 | Argentina | 2026 | NaN                         |

```
In [16]: variable_pais = df_pais_fechas["Annual change in population"]

media_pais = variable_pais.mean()
mediana_pais = variable_pais.median()
varianza_pais = variable_pais.var()
desviacion_estandar_pais = variable_pais.std()

print(f"Media ({pais}, 2006-2026):", media_pais)
print(f"Mediana ({pais}, 2006-2026):", mediana_pais)
print(f"Varianza ({pais}, 2006-2026):", varianza_pais)
print(f"Desviación estándar ({pais}, 2006-2026):", desviacion_estandar_pais)
```

Media (Argentina, 2006-2026): 351200.8888888889

Mediana (Argentina, 2006-2026): 406355.5

Varianza (Argentina, 2006-2026): 14819162677.281046

Desviación estándar (Argentina, 2006-2026): 121733.98324741142

## Resultados

- **Fuente:** United Nations, World Population Prospects (2024), procesado por Our World in Data.
- **DataFrame cargado correctamente:** 38,400 filas × 5 columnas, con 256 entidades distintas.
- **Estructura:** columnas `Entity`, `Code`, `Year`, `Annual change in population` y `Annual population change (Projected)`; `Year` es `int64` y las columnas numéricas de cambio poblacional son `float64`, con valores faltantes en `Code` y en ambas variables de cambio poblacional.
- **Estadísticos (año 2020, "Annual change in population"):** media  $\approx 2,124,908.85$ , mediana = 34,293.5, desviación estándar  $\approx 9,522,989.82$ , mínimo = -494,016 (Venezuela), máximo = 75,707,590 ("World").
- **Entorno verificado:** versiones de Python, Pandas y NumPy comprobadas en la Actividad 4, y el notebook se reproduce correctamente al ejecutarse desde el inicio.